InnoCite 开发日志

项目：InnoCite —— 学术论文创新点提炼与跨学科推荐系统（iCAN 大学生创新创业大赛备赛项目）

技术栈：Flask + SQLite + scikit-learn（TF-IDF）+ sentence-transformers（SBERT）+ DeepSeek LLM + jieba/KeyBERT + pdfplumber/reportlab + Plotly

记录区间：2026-06-10 ~ 至今（持续追加）

数据来源：

2026-08-18 前：**依据项目文件修改时间戳还原**（当时无工作日志，以下 6 月阶段为文件级客观事实）

2026-08-18 后：`.workbuddy/memory/` 每日工作日志 + 文件时间戳交叉验证

一、项目概况

面向科研人员/高校学生的**学术论文创新点提炼与跨学科推荐系统**：导入 arXiv/PDF 论文后，自动提炼"问题-方法-效果"三要素创新点、基于语义做跨学科推荐、生成热度趋势与 PDF 综合报告。采用 **LLM 主力 + 规则引擎兜底的双轨架构**，断网/无 Key 时自动降级。

里程碑总览

日期	阶段	关键成果	依据
06-10 ~ 06-26	核心功能搭建	全量路由/页面/前端、报告生成、界面截图、架构图四件套	文件时间戳
08-18	优化第一波（P0×4 + P1×3）	数据去真实化、GROBID 启用、鉴权、评估闭环（ROUGE-L 46.46%）、断网链路	日志+时间戳
08-19	通篇分析 + 真实验证	正文入库/提取、真实论文 3/3 提升、推荐吃正文、SBERT 启用（8.1x）	日志+时间戳
08-20	P2 并发 + 工程清理	线程安全、WAL、LLM 缓存落库、/healthz、16 项测试、第一梯队闭环	日志+时间戳
08-21	收尾 + 汇报 PPT	getter 收敛、config	日志+时间戳

		时序修复、21 页 PPT、项目清理打包	

二、分日开发详情

阶段 0：2026-06 核心功能搭建（文件时间戳还原）

此阶段无工作日志记录，以下按项目文件修改时间戳还原开发轨迹，仅陈述文件级事实。

日期	变更文件	对应功能
06-10	data/stopwords.txt	中文停用词表
06-11	routes/__init__.py、templates/timeline.html	蓝图注册 + 时间线页
06-12	文件/使用指南.md、static/js/paper-detail.js、charts.js、recommend.js	使用文档 + 论文详情/图表/推荐前端
06-17	config.py、templates/login.html、recommend.html、paper_detail.html、static/css/style.css	配置 + 登录/推荐/详情页
06-20	routes/auth.py、papers.py、recommend.py、trends.py、evaluate.py、bookmarks.py；templates/index.html、bookmarks.html、evaluate.html；static/js/main.js、report.js、trends.js；report_generator.py、utils/gzip_middleware.py	**核心功能集中搭建日：**认证/论文库/推荐/热度/评估/收藏六蓝图 + 首页/报告/趋势前端 + PDF 报告生成 + gzip 压缩中间件
06-22	截图/登录页面.png、首页.png、热度趋势界面.jpeg、使用说明.jpeg、API 文档界面.jpeg	功能已成型，截图留档
06-26	scripts/generate_class_diagram.py、generate_architecture.py、generate_pdf_flow.py、generate_er_*.py；output/ 类图/ER 图/架构图/流程图（pdf+png+svg 共 12 个）	架构文档四件套生成

小结：6 月完成系统从零到可用的核心开发，主力开发集中在 6/20（一天落全部业务蓝图）；6/26 产出完整架构文档。此阶段无创新点评估闭环、无 SBERT。

2026-08-18（周一）｜优化第一波：P0×4 + P1×3（iCAN 备赛）

目标：让系统跑通并按 V4 优化方案处理 P0/P1 问题。文件时间戳集中在 14:18–14:40。

环境搭建

- 项目无 Python 依赖，创建 venv（Python 3.13.12），安装核心依赖（清华镜像）。

- sentence-transformers（torch 过重）未装 → SBERT 不可用，自动回退 TF-IDF 双轨。
- 应用启动成功（5000 端口）；数据库：20 篇论文 / 20 条创新点 / 1 用户 / 49 条推荐缓存。

P0 优化（4 项）

#	项	说明	时间戳佐证
1	示例数据去真实化	20 篇借用真实论文的数据改为自创合成数据	14:18 preset_innovations.json
2	嵌入维度修复	硬编码 768 → 动态获取（实际 384）	14:21 templates/about.html、scripts/generate_er_*.py
3	GROBID 死代码	新建 grobid_client.py，GROBID 分支真正可用	—
4	管理接口鉴权	is_admin + admin_required（401/403）	14:22 routes/admin.py、utils/response.py

验证：管理员 200 / 普通用户 403 / 未登录 401；数据库重建成功；全部页面 200。

P1 优化（3 项）

1. **数据一致性统一失效**：缓存失效覆盖 insert/update/delete 三事件（14:29 `keyword_trend.py`）。
2. **评估闭环跑通**：`ground_truth.json` v2.0 按 arxiv_id 匹配（14:32）；修复隐藏 bug——`get_llm_client` 只在传 config 时初始化导致 LLM 分类从未生效；指标：创新点 ROUGE-L **46.46%**、分类 Accuracy **75%**、关键词 F1@5 **13%**（14:37 `evaluation_report.json`）。
3. **断网演示链路**：CDN 全部本地化（14:37-14:38 `static/vendor/` 9 个文件 + `base/report/trends.html`）；kaleido 使 PDF 含图表（14:40 `demo_report.pdf`）。

经验：pip 沙箱装包必须 `--no-cache-dir`；taskkill `//F` 报错改用 PowerShell；大文件行号替换用脚本更稳。

2026-08-19（周二）｜通篇分析改造 + 真实论文验证 + SBERT 启用

目标：回答"推荐/创新点只靠摘要，可信度存疑"。文件时间戳集中在 09:54–10:13。

F1 入库补正文

- `paper_parser.py` 新增 `_fetch_arxiv_fulltext()` 三级回退抓正文（10:03）；合成数据每篇补 full_text（09:54 `sample_papers.json`）。

F2 创新点通篇分析

- LLM 提示词改"通读摘要与正文"，正文按章节拆分注入（每节 1200 字、总预算 3600）。

F3 评估对比（关键结论）

- 合成数据上通篇 ROUGE-L **40.51%** vs 仅摘要 **46.46%**——略降。根因：合成正文 = 摘要句子重排，无新增信息。**评估闭环客观暴露"改动是否真正变好"，这正是其价值**。

真实论文验证（R1-R3 完成）✓

- 顺带修复隐藏 bug：`import_arxiv_by_id` 用旧 API `search.results()`（arxiv 4.x 已改），单篇导入此前从未跑通。
- 3 篇真实论文正文全部抓取成功：Swin(71.7K) / BERT(65.5K) / FedAvg(54.3K)。
- 真实对比（10:11 `ground_truth_real.json`、`real_comparison_eval.py` → 10:13 报告）：**3/3 通篇更优**，平均 +1.3%（method 维度 +3.5% 最显著）：

论文	仅摘要	通篇	Δ
Swin Transformer	27.7%	28.1%	+0.4%
BERT	25.9%	27.5%	+1.6%
FedAvg	12.3%	14.2%	+1.9%

推荐向量吃正文（V1-V2）

- `_paper_to_text` 注入正文章节节选；Swin 与 Autoregressive 相似度 0.0915→0.1073（+17%），推荐从"词面相似"转向"方法架构相似"。

SBERT 安装启用（S1-S2）✓

- 安装 sentence-transformers 6.0 + torch 2.13；模型经 hf-mirror 手动下载 13 个文件到本地（绕开代理 HEAD 失败）。
- 量化对比：Swin↔BERT 相似度 **0.0593 → 0.4797（8.1x）**；跨学科 Top3 全部命中 Transformer 架构相关论文。

经验：scripts/ 下脚本需 `sys.path.insert(0, 项目根)`；huggingface 下载失败可用 hf-mirror 逐文件下载。

2026-08-20（周三）｜P2 并发安全 + 工程清理 + 第一梯队收尾

目标：处理 P2（后台线程共享 session、SBERT encode 无锁）与工程清理项。文件时间戳集中在 13:13–13:25（约一小时内完成）。

完成的修改（6 项）

#	项	时间戳佐证
1	task_queue 独立 session + SQLite WAL + busy_timeout	13:13 utils/task_queue.py、13:15 app.py
2	SBERT encode 线程安全（threading.Lock 串行化）	13:14 utils/sbert_manager.py、keybert_extractor.py、paper_classifier.py
3	代码清理（__import__、私	13:14 routes/report.py、13:20

	有方法、query.get()、embedding_dim 兼容）	recommender.py
4	/healthz 健康检查	13:15 app.py
5	LLM 缓存落库（LLMCache 表）	13:16 llm_client.py、models.py
6	最小测试集（pytest + 16 用例）	13:17-13:19 pytest.ini、conftest.py、3 个 test_*.py

验证：16 测试全过；57 路由冒烟、healthz 200；后台任务独立 session 内 LLM 提取成功落库。

第一梯队收尾（补齐 3 项）

4. **init_db.py 幂等去重**（13:23）：按 arxiv_id 查重跳过（23→23）。
5. **requirements 锁版本 + 移除 flask-compress**（13:24）。
6. **GROBID 探测延迟优化**（13:24）：TTL 缓存（可用 5min / 不可用 30s），~4s → 0.000s。

验证：16 测试全过，healthz 200，论文 23 篇。第一梯队全部闭环。

2026-08-21（周四）｜**收尾收敛 + 汇报 PPT + 项目清理**

目标：V4 方案剩余工程项清零 + 让汇报 PPT 与最新状态一致。

双套 get_llm_client getter 收敛（09:38 `routes/helpers.py`）

- 删除 `_llm_client` 缓存，改为纯委托；修复 `reset_llm_client()` 只重置一半的缺陷。验证：双入口同一实例 / reset 后一致 / 无 context 返回 None。

InnovationExtractor config **时序隐患修复**（09:41 `innovation_extractor.py`）

- 模块级不传 config → `LLM_INNOVATION_ENABLED` 开关失效；新增 `_resolve_config()` + 实时评估。验证 4 种组合正确。至此 **V4 方案全部工程清理项落地**。

汇报 PPT 与素材（13:30-15:20）

- 13:30 演示视频.mp4、13:34-13:37 三张新截图（论文库/跨学科推荐/综合报告）→ 用于 PPT。
- 15:20 文件/`InnoCite` 项目技术汇报`.pptx` 最终版（21 页，3.30MB）。
- PPT 迭代史：修正 3 页过时内容 → 丰富化 5 页 + 插 6 图 → 重构 15→21 页截图独立成页 → 清理只留 pptx。踩坑：auto_size 溢出、链式替换误改、索引漂移。

项目清理与代码打包

- 删除 V4 优化方案 md、`.vscode/`、`.claude/`；`USER_GUIDE.md` → 使用指南`.md`；新增 `.gitignore`。
- 生成最小代码包 `d:/InnoCite_项目代码包_20260821.zip`（8.9MB，102 文件），验证无敏感信息泄漏。

三、关键量化成果汇总

指标	数值	说明
创新点提取 ROUGE-L（LLM）	**46.46%**	vs 规则引擎 0.6%，提升约 77 倍
真实论文通篇提升	平均 +1.3%（3/3 篇更优）	method 维度 +3.5% 最显著
学科分类 Accuracy	**75%**	cs.CV/cs.CL 100%，cs.AI 16.7%（AI vs LG 边界）
关键词 F1@5	13%（TF-IDF 回退）	KeyBERT 启用后待复测
SBERT vs TF-IDF 相似度	0.059 → 0.480（8.1x）	词面相似 → 方法架构相似
单元测试	16/16 通过	规则提取/推荐/评估三模块
路由/页面	57 路由全部 200	断网本地化后无 CDN 依赖

四、技术踩坑与经验（汇总）

领域	坑	解法
环境	pip 沙箱缓存清理报 SAFE_DELETE_FAIL_CLOSED 回滚	安装加 --no-cache-dir
Windows	Git Bash 下 taskkill //F 报错	用 PowerShell Stop-Process
arxiv API	旧 search.results() 在 arxiv 4.x 失效（单篇导入从未跑通）	arxiv.Client().results(search) + 限流参数
huggingface	代理下 hub HEAD 请求失败	hf-mirror 逐文件下载组织标准模型目录
评估	数据库重建后 id 不稳定	ground truth 按 arxiv_id 匹配
LLM 集成	get_llm_client 只在传 config 时初始化 → 内部调用拿 None	从 current_app.config 自动获取
并发	后台线程共享 session	独立 session + WAL + busy_timeout
PPT	链式文本替换误改、索引漂移误删页脚	按 shape 索引精确定位 + 对象引用删除

五、当前状态与遗留

当前状态：核心功能（6 月）+ V4 方案 P0/P1/P2 + 工程清理项（8 月）全部落地；系统 23 篇论文（20 合成 + 3 真实）；SBERT 本地模型启用；LLM 走 DeepSeek；21 页技术汇报 PPT 与项目状态一致；最小代码包已产出。

遗留事项：

7. **V4 Pro 四个展示功能**（关系图谱 / Dashboard / 创新点对比 / 管理可视化页）——用户明确留待后续方案。
8. 关键词 F1@5 偏低（13%），KeyBERT 启用后复测。
9. cs.AI 分类准确率 16.7%（AI vs LG 边界），可细化学科描述或加消歧示例。

10. requirements 已锁版本，未验证全新环境一键安装。

日志维护说明：早期阶段（2026-08-18 前）依据文件修改时间戳还原，仅含文件级事实；2026-08-18 起以工作日志为主、时间戳交叉验证。后续每完成一个阶段，将当日日志收敛进对应章节。